

Aufgaben des Datenmanagement-Praktikums

Die Lösungen der Aufgaben sind **48 Stunden vor** dem gewählten Termin online im [Lernraum-Kurs zur Lehrveranstaltung](#) per Upload einzureichen. Bei der Bezeichnung der Upload-Dateien bitte folgendes Muster einhalten:

DM_<Vorname>_<Nachname>_<Übungsnr>.<Dateierweiterung>

Zum Beispiel DM_Max_Zimmermann_B1.ipynb für die Lösung des Teams von Max Zimmermann zu Übung B1 im Format eines Jupyter-Notebooks. Eine Abgabe pro Team durch einen beliebigen Teilnehmer ist ausreichend. Die sinnvollen Dateierweiterungen können zwischen den Übungen variieren (.ipynb, .pdf, .zip, ...).

Beurteilung

In den folgenden 5 Aufgaben können jeweils 1 bis 15 Punkte erreicht werden. Also insgesamt maximal 75 Punkte. Die Vergabe der Noten erfolgt hierbei mit nachfolgenden Notenstufen.

Punkte	≥ 93%	< 93% ≥ 90%	< 90% ≥ 87%	< 87% ≥ 83%	< 83% ≥ 80%	< 80% ≥ 77%	< 77% ≥ 73%	< 73% ≥ 70%	< 70% ≥ 67%	< 67% ≥ 33%	< 33%
Note	1	1.3	1.7	2	2.3	2.7	3	3.3	3.7	4	5

B1: Explorative Analyse und Regression

In dieser Übung sollen Regressionsmodelle auf Basis verschiedener Beispieldaten entwickelt werden. Die grundsätzliche Aufgabenstellung ist für alle Datensätze gleich. Wählen Sie ein Anwendungsszenario.

Anwendungsszenario	Datenbasis zur Regression
A	Bike Sharing
B	Liver Disorder
C	Road Traffic
D	Forest Fires
E	Metro Traffic Volume
F	Real estate valuation

Die Aufgaben sind in einem Jupyter-Notebook mit geeigneten Python-Bibliotheken zu bearbeiten.

Aufgabenstellung:

- Bestimmen Sie **Lage** und **Streuung** aller Merkmale inkl. Zielvariablen. Die Parameter für Lage und Streuung sind selbst zu wählen. Welche zwei Merkmale sind sich bzgl. Lage und Streuung am ähnlichsten bzw. am unähnlichsten? Sollte der Datensatz standardisiert werden? Begründen Sie.
- Visualisieren** Sie die Merkmale nach einer **Standardisierung** (Die Methode ist selbst zu wählen) in einem Boxplot. Vergleichen Sie die standardisierten Daten mit den originalen Daten. Was fällt Ihnen auf?

Auf Basis der Daten soll im Folgenden sukzessive das Zielmerkmal y aus den anderen Merkmalen $x_1, \dots, x_n$ vorhergesagt werden. Das Zielmerkmal kann der u.s. Tabelle entnommen werden.

- Visualisieren Sie zunächst den linearen Zusammenhang zwischen y und jedem einzelnen Merkmal x_i in einem **Streuungsdiagramm** bzw. **Pairplot**. Welches Merkmal hat den stärksten linearen Zusammenhang mit dem Zielmerkmal? Welche Merkmale erscheinen nutzlos? Erläutern Sie anhand der visuellen Darstellung des Streuungsdiagramms/Pairplots!

Daten zur Regression	Zielmerkmal y	Anzahl der Merkmale x_i
<i>Bike Sharing</i>	<i>cnt</i>	13 ("casual", "registered" & "instant" auslassen)
<i>Liver Disorder</i>	<i>drinks</i>	6
<i>Road Traffic</i>	<i>Cross 6</i>	6
<i>Forest Fires</i>	<i>area</i>	12
<i>Metro Traffic Volume</i>	<i>traffic_volume</i>	8
<i>Real estate valuation</i>	<i>Y house price unit area</i>	6 (Merkmal No" auslassen)


- Bestimmen Sie die **Korrelationskoeffizienten** zwischen y und jedem Merkmal x_i und **interpretieren** Sie die Werte. Was besagt ein negativer bzw. positiver Korrelationskoeffizient?
- Ermitteln Sie das **Bestimmtheitsmaß** für ein multivariates lineares Regressionsmodell, das alle geeigneten Merkmale $x_1, \dots, x_m$ zur Bestimmung von y berücksichtigt. Verwenden Sie dazu die Methoden `sklearn.linear_model.LinearRegression.fit/predict` und `sklearn.metrics.r2_score`. Leiten Sie geeignete Merkmale aus Teil c. ab. Überführen Sie kategorische Variablen in geeignete Repräsentationen.
- Teilen Sie den Datensatz in Testdaten (20%) und potentielle Trainingsdaten (80%) auf. Berechnen Sie die Güte für **5 Regressionsmodelle**, die auf unterschiedlichen Größen (10%,

20%, 40%, 80% und 100%) der potentiellen Trainingsdaten $x_1, \dots, x_m$ trainiert und jeweils auf den **Testdaten** getestet werden. Der Schnitt der Trainingsdaten soll zufällig passieren. Wenn es z.B. 100 Zeilen in den Trainingsdaten gibt, so ziehen Sie 10 zufällige Zeilen für 10%, 20 zufällige Zeilen für 20% usw. Wobei Sie bitte immer den gleichen Seed verwenden, e.g. 20% der Daten beinhalten die 10% aus dem Schnitt zuvor plus 10% neue, zufällig gezogene Daten. Das Maß für die Güte ist frei wählbar. Plotten Sie die 5 Werte als [Liniendiagramm](#), sortiert nach Größe der verwendeten Trainingsdaten von klein nach groß (siehe Beispiel unten). [Was können Sie beobachten? Welches Modell empfehlen Sie? Begründen Sie Ihre Antwort!](#)

- g. Wählen Sie das Merkmal aus $x_1, \dots, x_m$ aus, über das sich y am besten anhand der vorliegenden Trainingsdaten vorhersagen lässt. Begründen Sie Ihre Wahl. [Visualisieren](#) Sie für das gewählte Merkmal die einfachen [polynomialen Regressionsmodelle](#) für Polynome 1. bis 3. Ordnung über die Methode `seaborn.regplot` und [vergleichen](#) Sie deren [Bestimmtheitsmaße \$R^2\$](#) . Beurteilen Sie die Modelle hinsichtlich [Under- und Overfitting](#). Begründen Sie Ihre Beurteilungen.
- h. Machen Sie aus dem Regressionsproblem ein Klassifikationsproblem. Überführen Sie dafür die Zielvariable in eine passende Darstellung und trainieren Sie eine Logistische Regression (2/3 Training und 1/3 Test) mit der Methode `sklearn.linear_model.LogisticRegression`, mit `lbfgs` als Solver über alle geeigneten Merkmale $x_1, \dots, x_m$. Eine Doku zu den Parametern finden Sie hier: [Logistic Regression](#). Ermitteln Sie die Genauigkeit für Trainings- und Testdatensatz. Sind Sie zufrieden mit dem gelernten Modell? Wie können Sie die Performance des Modells weiter steigern?

Laden Sie die Lösungen zu den Aufgaben als Jupyter-Notebook (.ipynb) in den [Lernraum](#) hoch.

Präsentieren Sie Ihre Lösungen zu den Teilaufgaben in maximal 15 Minuten. Neben den Lösungen zu den o.g. Teilaufgaben, sollen Sie zu Beginn der Präsentation Ihr jeweiliges Anwendungsszenario kurz vorstellen: Welches Regressionsproblem ist im Datensatz enthalten? Welche Merkmale gibt es? Versuchen Sie den Rest der Gruppe abzuholen.



Beispiel: Liniendiagramm für die Güte