

Aufgaben des Datenmanagement-Praktikums

Die Lösungen der Aufgaben sind **48 Stunden vor** dem gewählten Termin online im [Lernraum-Kurs zur Lehrveranstaltung](#) per Upload einzureichen. Bei der Bezeichnung der Upload-Dateien bitte folgendes Muster einhalten:

DM_<Vorname>_<Nachname>_<Übungsnr>.<Dateierweiterung>

Zum Beispiel DM_Max_Zimmermann_B1.ipynb für die Lösung des Teams von Max Zimmerman zu Übung B1 im Format eines Jupyter-Notebooks. Eine Abgabe pro Team durch einen beliebigen Teilnehmer ist ausreichend. Die sinnvollen Dateierweiterungen können zwischen den Übungen variieren (.ipynb, .pdf, .zip, ...).

Beurteilung

In den folgenden 5 Aufgaben können jeweils 1 bis 15 Punkte erreicht werden. Also insgesamt maximal 75 Punkte. Die Vergabe der Noten erfolgt hierbei mit nachfolgenden Notenstufen.

Punkte	≥ 93%	< 93% ≥ 90%	< 90% ≥ 87%	< 87% ≥ 83%	< 83% ≥ 80%	< 80% ≥ 77%	< 77% ≥ 73%	< 73% ≥ 70%	< 70% ≥ 67%	< 67% ≥ 33%	< 33%
Note	1	1.3	1.7	2	2.3	2.7	3	3.3	3.7	4	5

B2: Clusteranalyse und Klassifikationsbäume

Teil 1: Grundlagen der Clusteranalyse

Bitte wählen Sie eine Datenbasis in Abhängigkeit des Anwendungsszenarios Ihres Teams aus Aufgabe B1. Diese Aufgabe ist in einem Jupyter-Notebook mit Python und Scikit-Learn zu bearbeiten.

Aufgabenstellung

- Erstellen Sie die paarweise Distanzmatrix über die Datenpunkte. Das Distanzmaß ist die euklidische Distanz. Welche zwei Punkte sind sich am nächsten?
- Führen Sie ein agglomeratives Clustering mit *Single Linkage*, *Complete Linkage* und *Centroid Linkage* durch und erstellen Sie jeweils das vollständige Dendrogram. Wählen sie das für Sie beste Clustering aus und begründen Sie Ihre Antwort.
- Führen Sie ein Clustering mittels DBSCAN durch. Stellen Sie die zwei Parameter *eps* und *MinPts* des DBSCAN so ein, dass genau zwei gültige Cluster entstehen (Ausreißer ist kein Cluster). Welche Punkte sind dann Grenzinstanten, Kerninstanten und Geräuschinstanten?
- Erstellen Sie eine Heatmap (mittels *seaborn.heatmap*) der Distanzmatrix unter Berücksichtigung der euklidischen Distanz und des ermittelten Clusterings des DBSCAN (d.h. ordnen Sie zunächst die Punkte mit Bezug zu den Clustern und erstellen Sie anschließend eine Distanzmatrix auf die neu geordneten Punkte). Interpretieren Sie anhand der Matrix die Güte des Clusterings. Ist es ein gutes Clustering?

6 Datensätze mit 2 Merkmalen und jeweils 7 Datenpunkten

Anwendungs- szenario	Daten																								
A	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>X</th><td>12</td><td>6</td><td>4</td><td>1</td><td>0</td><td>3</td><td>6</td></tr><tr><th>Y</th><td>2</td><td>1</td><td>10</td><td>6</td><td>3</td><td>0</td><td>12</td></tr></table>		0	1	2	3	4	5	6	X	12	6	4	1	0	3	6	Y	2	1	10	6	3	0	12
	0	1	2	3	4	5	6																		
X	12	6	4	1	0	3	6																		
Y	2	1	10	6	3	0	12																		
B	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>X</th><td>7</td><td>0</td><td>1</td><td>8</td><td>5</td><td>10</td><td>12</td></tr><tr><th>Y</th><td>2</td><td>9</td><td>12</td><td>1</td><td>7</td><td>5</td><td>0</td></tr></table>		0	1	2	3	4	5	6	X	7	0	1	8	5	10	12	Y	2	9	12	1	7	5	0
	0	1	2	3	4	5	6																		
X	7	0	1	8	5	10	12																		
Y	2	9	12	1	7	5	0																		
C	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>X</th><td>1</td><td>0</td><td>12</td><td>3</td><td>6</td><td>3</td><td>9</td></tr><tr><th>Y</th><td>7</td><td>12</td><td>12</td><td>0</td><td>0</td><td>4</td><td>10</td></tr></table>		0	1	2	3	4	5	6	X	1	0	12	3	6	3	9	Y	7	12	12	0	0	4	10
	0	1	2	3	4	5	6																		
X	1	0	12	3	6	3	9																		
Y	7	12	12	0	0	4	10																		
D	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>X</th><td>12</td><td>7</td><td>8</td><td>4</td><td>0</td><td>7</td><td>4</td></tr><tr><th>Y</th><td>2</td><td>0</td><td>1</td><td>8</td><td>5</td><td>5</td><td>12</td></tr></table>		0	1	2	3	4	5	6	X	12	7	8	4	0	7	4	Y	2	0	1	8	5	5	12
	0	1	2	3	4	5	6																		
X	12	7	8	4	0	7	4																		
Y	2	0	1	8	5	5	12																		
E	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>x</th><td>1</td><td>0</td><td>12</td><td>8</td><td>6</td><td>3</td><td>9</td></tr><tr><th>y</th><td>7</td><td>9</td><td>12</td><td>8</td><td>10</td><td>4</td><td>10</td></tr></table>		0	1	2	3	4	5	6	x	1	0	12	8	6	3	9	y	7	9	12	8	10	4	10
	0	1	2	3	4	5	6																		
x	1	0	12	8	6	3	9																		
y	7	9	12	8	10	4	10																		
F	<table><tr><th></th><th>0</th><th>1</th><th>2</th><th>3</th><th>4</th><th>5</th><th>6</th></tr><tr><th>X</th><td>1</td><td>0</td><td>4</td><td>8</td><td>6</td><td>3</td><td>7</td></tr><tr><th>Y</th><td>7</td><td>9</td><td>7</td><td>8</td><td>10</td><td>2</td><td>9</td></tr></table>		0	1	2	3	4	5	6	X	1	0	4	8	6	3	7	Y	7	9	7	8	10	2	9
	0	1	2	3	4	5	6																		
X	1	0	4	8	6	3	7																		
Y	7	9	7	8	10	2	9																		

Teil 2: Partitionierende Clusteranalyse und Klassifikationsbäume

Diese Aufgabe ist in einem Jupyter-Notebook mit Python und Scikit-Learn zu bearbeiten.

Aufgabenstellung

- a) Generieren Sie 1000 künstliche Datensätze (*samples*) mit 5 metrischen Merkmalen (*features*) über die Scikit-Learn-Methode `make_blobs`. Jeder Datenpunkt soll einer von 4 Zielklassen (Klassenausprägungen (*centers*)) zugeordnet sein.

```
make_blobs(n_samples=1000, n_features=5, centers=4, cluster_std=3, random_state=RS)
```

Zwecks Vergleichbarkeit der Ergebnisse soll der Zufallszustand (*random state*) in Abhängigkeit des Anwendungsszenarios gewählt werden:

Anwendungsszenario	Random State RS
A	0
B	1
C	2
D	3
E	4
F	5

Nehmen Sie an, dass die 5 erzeugten Merkmale messbare Eigenschaften von 1000 Kunden entsprechen, die in 4 Gruppen wie z.B. Bonitäts- oder Prioritätsklassen segmentiert werden sollen.

- b) Visualisieren Sie die Abhängigkeiten zwischen diesen 5 Merkmalen über die Methode `seaborn.pairplot`. Verwenden Sie den Parameter `hue` der Methode um die Zielklassen in verschiedenen Farben darzustellen. Welches einzelne Feature eignet sich anhand des Plots am besten für das Clustering und warum?

- Partitionierendes Clustering -

- c) Führen Sie ein partitionierendes Clustering nach dem k-Means-Verfahren mittels `sklearn.cluster.KMeans` durch. Setzen Sie dabei den Zufallszustand wie oben angegeben.
- d) Berechnen Sie die Genauigkeit des Clusterings mit einer von Ihnen gewählten geeigneten Evaluationsmetrik. Begründen Sie ihre Wahl. Wie bewerten Sie das Clustering anhand der gewählten Metrik?
- e) Geben Sie die Konfusionsmatrix (`sklearn.metrics.confusion_matrix`) für das Clustering mittels der Methode `seaborn.heatmap` aus und interpretieren Sie das Ergebnis. Ist die Konfusionsmatrix ein geeignetes Werkzeug, um das Clustering zu bewerten?

- Klassifikationsbaum -

- f) Teilen Sie die Datensätze in Trainingsdaten (80%) und Testdaten (20%) mittels der Methode `sklearn.model_selection.train_test_split`. Setzen Sie dabei den Zufallszustand wie oben angegeben. Nutze Sie die Centers als Zielklassen.
- g) Trainieren Sie einen Klassifikationsbaum mittels `sklearn.tree.DecisionTreeClassifier` anhand der Trainingsdaten. Das Unreinheitsmaß soll der Gini-Index (`criterion="gini"`) sein. Die minimale Verbesserung der Unreinheit für einen Split soll 0,05 (`min_impurity_decrease = 0.05`) betragen. Die anderen Parameter können Sie in den default Werten belassen.
- h) Visualisieren Sie den resultierenden Klassifikationsbaum mittels der Methode `sklearn.tree.plot_tree` (mit Parameter `filled=True`) und interpretieren Sie die Blätter des Baums: Welches Blatt ist für die Bestimmung von Klasse 2 am geeignetsten? Zeigen Sie anhand der Visualisierung, wie der Entscheidungsbaum einen Datenpunkt der Klasse 4 klassifiziert.

- i) Testen Sie die Genauigkeit des Klassifikationsbaums anhand der Testdaten: Geben Sie die Konfusionsmatrix für den Klassifikationsbaum mittels der Methode `seaborn.heatmap` aus. Bei welcher Klasse macht der Entscheidungsbaum die meisten Fehler?
- j) Untersuchen Sie, wie sich die Genauigkeit des Entscheidungsbaumes in Abhängigkeit zu der Größe des Baumes entwickelt. Variieren Sie dafür den Parameter `min_samples_leaf` [400, 200, 100, 50, 25, 12, 6, 2] und tragen Sie die Ergebnisse in einem Diagramm ab:
 - X-Achse -> `min_samples_leaf`
 - Y-Achse -> Accuracy
 - 2 Kurven: Trainingsset & Testset

Wie interpretieren Sie die Ergebnisse hinsichtlich des Parameters `min_samples_leaf`? Machen Sie sich bewusst, was der Parameter `min_samples_leaf` bedeutet. Das Verhältnis 80:20 für die Datensätze Training/Test ist weiterhin beizubehalten.

- Random-Forest-Klassifikator -

- k) Trainieren Sie einen Random-Forest-Klassifikator, der aus 20 Bäumen bestehen soll, mittels `sklearn.ensemble.RandomForestClassifier`. Setzen Sie dabei den Zufallszustand wie oben angegeben.
- l) Testen Sie den Random-Forest-Klassifikator anhand der Testdaten und geben Sie wiederum die Genauigkeit und die Konfusionsmatrix aus. Vergleichen Sie die Ergebnisse mit den vorherigen Genauigkeiten und Konfusionsmatrizen.
- m) Erzeugen Sie einen Bericht der Klassifikation und erklären Sie die Begriffe der Ausgabe. Hierfür können Sie die Methode `sklearn.metrics.classification_report` nutzen.

Laden Sie die Lösungen zu den Aufgaben als Jupyter-Notebook(s) (.ipynb) in den Lernraum hoch.