



Datenmanagement

Einführung

Bachelor Informatik/Softwaretechnik

Prof. Niklas Beuter, Max Sternitzke, Patrick Willnow



Modul	Datenmanagement
Modulverantwortlicher	Prof. Dr.-Ing. Max Zimmermann
ECTS-Credits	5 Vorlesung + 3 Praktikum = 8
SWS	4 Vorlesung + 2 Praktikum = 6

Workload

Präsenzstudium	90 h
Vorlesung	15 Wochen x 4 h = 60 h
Praktikum	15 Wochen x 2 h = 30 h
Selbststudium	ca. 150 h / 10 h je Woche
Workload je ECTS-Credit	240 h / 8 = 30 h

Prüfungsleistung	Klausur (90 Min.), Gewicht der Modulnote gemäß SPO : 67% Aufgaben des Praktikums, Gewicht für Modulnote gemäß SPO : 33%
-------------------------	--

Modulbeschreibung

Lehrinhalte

- Datenanalyse/Machine Learning
 - Einführung in überwachtes und unüberwachtes Lernen
 - Regression und Gradientenabstiegsverfahren
 - Klassifikation mit Entscheidungsbaumverfahren und Ensemble Modellen
 - Klassifikation mit probabilistischen Verfahren.
 - Unüberwachtes Lernen: Clusteranalyse und Assoziationsanalyse

ML – Do. 11:45

- Datenmanagement in transaktionsorientierten Anwendungen
 - Strukturierte Datenformate: XML, JSON und YAML
 - Web Services: REST
 - Objekt-Relationales Mapping
 - Multidimensionale Datenmodellierung

DM – Di. 10:00

- Datenmanagement in analyseorientierten Anwendungen
 - Aufbau eines Data Warehouse
 - Datenqualität und Datenintegration (ETL)
 - MapReduce mit Hadoop/Spark
 - Verteilte Datenverarbeitung

DM – Di. 10:00

Lernergebnisse

- Die Studierenden können eine API zum Datenaustausch zwischen Anwendungen entwerfen und implementieren. Sie kennen dazu erforderliche Datenformate und Kommunikationsprotokolle für Anwendungsentwickler.
- Die Studierenden kennen die Grundlagen eines analyseorientierten Informationssystems und können ein derartiges System gestalten.
- Die Studierenden verstehen grundlegende Methoden der statistischen und explorativen Datenanalyse und können sie auf kleine Datenmengen anwenden.
- Die Studierenden haben ihre Kompetenzen in Teamorganisation, Moderation, Konfliktlösung und Präsentationstechnik gestärkt.

Ansprechpersonen

- Datenanalyse/Machine Learning **ML – Do. 11:45**
 - Prof. Niklas Beuter
 - niklas.beuter@th-luebeck.de

- Datenmanagement in transaktionsorientierten Anwendungen **DM – Di. 10:00**
 - Max Sternitzke
 - max.sternitzke@th-luebeck.de

- Datenmanagement in analyseorientierten Anwendungen **DM – Di. 10:00**
 - Max Sternitzke
 - max.sternitzke@th-luebeck.de

- Praktikum – Allgemeine Organisation
 - Max Sternitzke
 - max.sternitzke@th-luebeck.de
- Praktikum – Spezifisches
 - Patrick Willnow
 - patrick.willnow@th-luebeck.de

Max Sternitzke
max.sternitzke@th-luebeck.de

Maschinelles Lernen (Donnerstag 11:45 – 13:15)

- Im Format „Inverted/Flipped Classroom“
- Wissensaneignung durch multimediales Online-Material in eigenständiger Arbeit.
- Vertiefende und interaktive Auseinandersetzung mit dem Gelernten anhand von Übungsaufgaben, die in der Präsenzveranstaltung besprochen werden.
- Es gibt je Woche einen Übungszettel, den Sie im Vorfeld der Präsenzveranstaltung bearbeiten.
- Anhand der Übungsaufgaben haben Sie die Möglichkeit 15% an zusätzlichen Klausurpunkten zu erhalten.
 - Je Aufgabe gibt es Punkte, die sie erhalten, wenn Sie die Aufgabe korrekt in der Präsenzveranstaltung präsentieren. Anmeldung erfolgt im Vorfeld direkt im Übungszettel an entsprechender Stelle ein.
 - Lösungen zu den Übungsaufgaben werden in Präsenz besprochen. Musterlösungen werden nicht herausgegeben; nutzen Sie die Präsenzveranstaltungen.

DM1 & DM2 (Dienstag 10:00 – 11:30)

- Im Format „klassische Vorlesung“
- Punktuell werden Multimedia Inhalte bereitgestellt.
- Sie können jeder Zeit inhaltliche Fragen zu Themen der Vorlesung stellen.

Praktische Übung der Vorlesungsinhalte

- Bearbeitung der Übungen in **3er**-Teams
- Teambildung während des ersten Praktikumstermins (oder im Voraus)
 - Jedes Team wählt gemeinsamen Praktikumstermin
 - Pro Termin sind 4 Teams (12 Personen) vorgesehen
- Pro Team Wahl eines Anwendungsszenarios (im Voraus First-Come-First-Served)

Praktikumstermine

- Für die Praktikumstermine gibt es 5 Aufgaben
- Es gibt 2 Arten von Praktikumsterminen:
 - Betreuung und Unterstützung in der Bearbeitung der Aufgaben ([Teilnahme optional](#))
 - Präsentation und Diskussion, der im Selbststudium erarbeiteten Lösungen zu den Aufgaben als Präsenzveranstaltung ([Teilnahme verpflichtend](#))
 - Praktikumsnote ergibt sich aus der Durchschnittsnote der 5 Aufgaben.
 - Es muss jede Teilaufgabe **bestanden** sein.

Praktikumsaufgaben

- Datenanalyse/Machine Learning
 - Explorative Analyse und Regression
 - Clusteranalyse und Klassifikationsbäume
 - Naive Bayes und Feature Engineering
- Datenmanagement in transaktionsorientierten Anwendungen
 - REST Web Services
- Datenmanagement in analyseorientierten Anwendungen
 - ETL mit Polars

Individuelle Leistungsbeurteilung

- + Qualität der Lösung und fristgerechter Upload im Lernraum **(48h vor dem Termin!)**
- + Qualifizierte mündliche Beiträge
- Erkennbar fehlende Mitarbeit an der Lösung
- Unkenntnis der Vorlesungsinhalte






Abgabefristen der Lösungen im Lernraum sind 48h vor dem Terminbeginn

- falls Nacharbeit erforderlich ist, kann eine überarbeitete Lösung zum nächsten Termin nachgefordert werden

Anwesenheit zu den Präsentationsterminen im Praktikum ist verpflichtend und Teil der Benotung

- Abmeldungen bei Krankheit o.ä. vorab beim Praktikumsbetreuer.
- Durch Krankheit o.ä. kann max. **1** Präsentationstermin versäumt werden.
- Bei jeder weiteren Abwesenheit wird die Präsentation in einem 1:1 Gespräch mit dem Praktikumsbetreuer nachgeholt. Hierfür müssen Sie aktiv auf den Praktikumsbetreuer zugehen.
- Fehlen ohne ärztliches Attest bedeutet „nicht bestanden“.

- Aurélien Géron: Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems; O'Reilly
- Jonas Freiknecht, Stefan Papp: Big Data in der Praxis – Lösungen mit Hadoop, Spark, HBase und Hive. Daten speichern, aufbereiten, visualisieren; Hanser
- Veit Köppen, Gunter Saake, Kai-Uwe Sattler: Data Warehouse Technologien; mitp
- Jason Myers & Rick Copeland: Essential SQLAlchemy – Mapping Python to Databases; O'Reilly
- Miguel Grinberg: Flask – Web Development; O'Reilly



KW	Datenmanagement (Dienstag)	Machine Learning (Donnerstag)	Präsentationen im Praktikum
13	Einführung Allgemein	Keine VL	--
14	Keine VL - Vollversammlung	Einführung Machine Learning	--
15	Ferien	Ferien	Ferien
16	Datenintegration - ETL	Keine VL	Teambildung (bis 11.04.); Einführung
17	Datenintegration - ETL	Lineare Regression	Optionale Teilnahme
18	Datenintegration - ETL	Polynomiale/Multivariate Regression	Optionale Teilnahme
19	Verteilte Datenverarbeitung (HDFS, Map/Reduce)	Logistische Regression/Gradientenabstieg	Präsentation Aufgabe B1
20	Verteilte Datenstromverarbeitung (Spark, Kafka)	Entscheidungsbäume	Optionale Teilnahme
21	Keine VL	Christi Himmelfahrt (Feiertag)	Kein Praktikum
22	Verteilte Datenverarbeitung (Spark)	Pruning/Ensemble-Verfahren	Präsentation Aufgabe A1
23	Datenmanagement in Verteilten Systemen	Clusteranalyse	Optionale Teilnahme
24	NoSQL Datenbanken	Evaluierung Überwacht/Unüberwacht	Präsentation Aufgabe B2
25	Multidimensionales Datenmodell	Bayes Klassifikation	Optionale Teilnahme
26	Strukturierte Datenformate (insb. XML, JSON)	Erweiterte Clusteranalyse / Dimensionsreduzierung	Präsentation Aufgabe B3
27	Objekt-Relationales Mapping	Assoziationsanalyse	Optionale Teilnahme
28	Klausurvorbereitung	Klausurvorbereitung	Präsentation Aufgabe A2
29	Klausurenwoche		



Datenmanagement

Einführung


Bachelor Informatik/Softwaretechnik

Prof. Niklas Beuter, Max Sternitzke, Patrick Willnow



Beispiel für Information, deren Beurteilung
von weiterem Wissen abhängig ist:

GameStop Corp. (GME)
NYSE - NYSE Delayed Price. Currency in USD
264.50 +4.50 (+1.73%)
At close: March 12 4:00PM EST



Pragmatik/Vernetzung

Information wird mit Erfahrungen verknüpft und ergibt Wissen.

Semantik

Aussagen/Daten wird eine Bedeutung zugewiesen.

Syntax

Einzelne Zeichen werden mittels einer Syntax zu einer Aussage geordnet.

Wir leben in der **Informationsgesellschaft** (nicht Softwaregesellschaft)
oder auch im **Informationszeitalter** (nicht Softwarezeitalter)

- Information = Rohstoff, Produkt, Wert
- Software = „nur“ ein Werkzeug zur Informations-/Datenverarbeitung
- Information ~ Daten in Strukturen und semantischem Kontext
- Daten-orientierte Lehrveranstaltungen im Bachelor-Studiengang Informatik/Softwaretechnik
 - Datenbanken (1. Semester)
 - Datenmanagement (4. Semester)

Bei der **Lehrveranstaltung Datenbanken** standen im Mittelpunkt

- konzeptionelle Datenmodellierung und ER-Modell
- relationales Datenbankmodell und Normalisierung
- Anfragesprache SQL
- Transaktionen und ACID-Prinzip
- Datenbankzugriff aus Anwendungen (JDBC)



Grundidee „Datenbanken – weiter gedacht“

Im Mittelpunkt stehen **Anwendungen mit spezifischen Anforderungen**

- einfacher Datenaustausch zwischen Anwendungen
- parallele/schnelle Verarbeitung sehr großer Datenmengen in analyse-orientierten Anwendungen
- Integration verschiedener Datenquellen → Datenqualität
- flexible Datenaufbereitung und statistische Datenanalyse

Technische Lösungen für obige Anforderungen

- Strukturierte Datenformate (XML/JSON)
- Web Services
- Big Data- und Data Warehouse-Systeme
- Machine Learning-Methoden




Relationale DBS sind seit vielen Jahren für eine Vielzahl an Anforderungen etabliert.


In den letzten Jahren sind datenintensive Anwendungen entstanden, deren Anforderungen relationale DBS und ihre Prinzipien (Normalisierung, ACID) nicht erfüllen:

- **sehr große Datenmengen,** *(Social Media, IoT → Big Data)*
- die in **sehr schneller Folge** entstehen *(Data Streams)*
- **sehr variable Datenstrukturen** *(Schemalosigkeit)*
- **flexible Adhoc-Datenanalysen** *(Business Intelligence, Machine Learning)*



Heute beruhen **kritische Geschäftsprozesse** in Unternehmen auf digitale verfügbare Informationen.





Quelle: <https://www.knime.com/blog/the-data-lifecycle>

Data Generation:


- Kunden mögen oder kommentieren Produkte in sozialen Medien.

Data Collection:

- Unternehmen verwenden Web-Scraping-Tools, um Daten aus sozialen Medien zu sammeln und diese in Kundenkaufdaten zu integrieren.

Data Processing:

- Unternehmen verarbeiten Social-Media-Daten, indem es wiederholte Beiträge, Kommentare oder identische Bewertungen, die auf verschiedenen Plattformen veröffentlicht wurden, entfernt. Dazu gehört auch die Korrektur von Inkonsistenzen bei Benutzernamen oder Hashtags sowie die Standardisierung von Datumsformaten.



Quelle: <https://www.knime.com/blog/the-data-lifecycle>

Data Storage:


- Unternehmen speichert Social-Media-Daten wie Kommentare, Bildunterschriften und Reaktionen sicher in Datenbanken und ermöglicht einen einfachen Zugriff für Analysen.

Data Management:

- Unternehmen führt Richtlinien ein, die gewährleisten, dass Kundendaten aus Quellen wie Facebook und Instagram sicher behandelt, regelmäßig bereinigt, validiert und alte Interaktionen archiviert werden.

Data Analysis:

- Unternehmen nutzt Techniken der natürlichen Sprachverarbeitung (NLP), um die Stimmung in sozialen Medien zu analysieren und gemeinsame Themen im Kundenfeedback zu identifizieren. Dies ermöglicht dem Unternehmen, gezieltere Marketingkampagnen zu entwickeln.



Quelle: <https://www.knime.com/blog/the-data-lifecycle>

Data Visualization:

- Unternehmen erstellt interaktive Dashboards, die Kennzahlen wie Social Shares, Kommentare und Follower-Wachstum im Zeitverlauf veranschaulichen, sowie Heatmaps, die das regionale soziale Engagement an verschiedenen Standorten zeigen.

Data Interpretation:

- Führungskräfte nutzen visualisierte Social-Media-Daten, um Kundenservice-Strategien zu optimieren und die allgemeine Kundenzufriedenheit zu steigern. Dies geschieht durch die Fokussierung auf Bereiche mit negativer Kundenstimmung.



Datenmanagement

Fragen?

Bachelor Informatik/Softwaretechnik

Prof. Niklas Beuter, Max Sternitzke, Patrick Willnow

