



Machine Learning

Was ist Machine Learning?

Prof. Dr.-Ing. Max Zimmermann

Maschinelles Lernen und verwandte Disziplinen zur Datenanalyse

“A computer program is said to **learn** from **experience E** with respect to some class of **tasks T** and **performance measure P** if its performance at tasks in **T**, as measured by **P**, improves with experience **E**” — Tom Mitchell (1997)“

Beispiel: Angenommen ein E-Mail Programm merkt sich, wie Sie E-Mails als Spam oder Nicht-Spam markieren (labeln). Basierend darauf lernt das Programm, wie es E-Mails besser filtern kann. Was ist **Task T** in der o.g. Definition?


- E-Mails als spam oder nicht-spam klassifizieren?
- Sich die Labels der E-mails merken?
- Die Anzahl von korrekt klassifizierten E-Mails?
- Nichts von alledem, das ist kein Machine Learning Problem.

Maschinelles Lernen (*Machine Learning*) unterscheidet Verfahren des

- überwachten Lernens (*Supervised Learning*) und
- unüberwachten Lernens (*Unsupervised Learning*).




Vorhersage des Immobilienpreis




Brustkrebs (Bösartig, Gutartig)

Klassifikation

diskreter Wert (0 oder 1)



Brustkrebs (2 Features: Alter und Größe)




Sie haben ein Unternehmen und wollen Machine Learning Algorithmen trainieren, die folgende zwei Probleme adressieren.

1. Sie haben eine große Stückzahl von einem Produkt und wollen vorhersagen, wie viele in den nächsten 3 Monaten verkauft werden.
2. Sie würden gerne anhand eines Programms prüfen, ob Kundenkonten gehackt bzw. gefährdet sind.



Sollten Sie die Aufgaben als Klassifikations- oder Regressionsproblem behandeln?

- Beides sind Klassifikationsprobleme
- Problem 1 ist ein Klassifikationsproblem, Problem 2 ein Regressionsproblem
- Problem 1 ist ein Regressionsproblem, Problem 2 ein Klassifikationsproblem
- Beides sind Regressionsprobleme



Beim Unüberwachten Lernen sind die Klassen der Daten nicht bekannt. Man sucht dann Datenpunkte, die ähnliche Merkmale aufweisen und bündelt diese zu einem Block ("Cluster").

Mit der Vorgabe von zwei Clustern könnten die beiden Cluster entstehen. Mit der Vorgabe von drei Clustern würde der Datenpunkt oben rechts potentiell ein eigenes Cluster bilden.




Regelbasierte (links) vs Machine Learning Clustering (rechts). Nach Regeln landen sehr ähnliche Kunden in unterschiedlichen Segmenten (Farben) nahe der Grenzen. Bei gelernten Clustern nach Dichteverteilung sind Kunden den ihnen ähnlichsten Kunden eindeutig zugewiesen, was zu einer besseren Kundenanalyse führt.

Maschinelles Lernen (*Machine Learning*) unterscheidet Verfahren des


- überwachten Lernens (*Supervised Learning*) und
- unüberwachten Lernens (*Unsupervised Learning*).



Überwachtes Lernen



Unüberwachtes Lernen




Überwachtes maschinelles Lernen kann in Verfahren zur


- **Klassifikation** und
- **Regression** untergegliedert werden.



Klassifikation



Regression



Qualitative vs. Quantitative Merkmale

- Qualitative Merkmale
 - Ausprägungen unterscheiden sich in ihrer Art (ordinal oder nominal skaliert).
- Quantitative Merkmale
 - Ausprägungen unterscheiden sich in ihrer Größe (metrisch oder stetig vs. kategorial oder diskret skaliert).

Skala


- Nominal (Unterscheidungsmerkmale)
 - Werte drücken nur Verschiedenartigkeit aus.
- Ordinal (Rangmerkmale)
 - Werte bringen eine natürliche Rangfolge zum Ausdruck.
- Metrisch (Abstandsmerkmale)
 - Intervallskala: Werte sind Zahlen, deren Abstände ($a - b$) verglichen werden können.
 - Verhältnisskala: Verhältnisse zwischen Zahlen (a / b) sind möglich, wenn Nullpunkt definiert ist.

Stetige Merkmale

- können jeden beliebigen reellen Wert in einem bestimmten Intervall annehmen
- haben eine nicht abzählbare Anzahl an Ausprägungen
- Ausprägungen werden durch Messen bestimmt und sind aufgrund von Messfehlern nur Näherungswerte
- Kontinuierliche Wahrscheinlichkeitsverteilung

Diskrete Merkmale

- haben endliche Anzahl an Ausprägungen
- Ausprägungen sind exakt bestimmbar
- Diskrete Verteilung



Überwachtes Lernen

- Klassifikation
 - Zuordnung von multivariaten Datenobjekten zu vorgegebenen Klassen
 - Abhängige Variable (= Klasse) ist **diskret** (→ nominal oder ordinal skaliert, endlich viele Ausprägungen)
- Regression
 - Bestimmung einer metrischen Zielvariable für multivariate Datenobjekte
 - Abhängige Variable ist **stetig** (→ metrisch skaliert)



Unüberwachtes Lernen

- Segmentierung (*Clustering*)
 - Datenobjekte werden Gruppen (ggf. unbestimmter Anzahl) zugeordnet
 - Objekte innerhalb einer Gruppe sind möglichst homogen zueinander
 - Objekte aus verschiedenen Gruppen sind möglichst heterogen zueinander

Lage- und Streuungsparameter sind Kennzahlen zur Beschreibung von Häufigkeitsverteilungen.

Lageparameter

- Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Modus

häufigster Wert

- Median

Wert an mittlerer Position nach Sortierung

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}} & n \text{ ungerade} \\ \frac{1}{2} (x_{\frac{n}{2}} + x_{\frac{n}{2}+1}) & n \text{ gerade} \end{cases}$$


- Median ist im Gegensatz zum arithmetischen Mittel robust gegen Ausreißer.
- Median kann auch bei ordinaler Skala eingesetzt werden.

Lageparameter

– Quantile

- Der Wert x_p für den $p\%$ der Beobachtungen kleiner und $(100-p)\%$ größer als x_p sind, heißt **p%-Quantil**
- 25%-Quantil = **unteres Quartil** (Q1)
- 50%-Quantil = **Median/Zentralwert** (Q2)
- 75%-Quantil = **oberes Quartil** (Q3)

Box-Whisker-Plot (oder kurz Boxplot)



IQR = Quartilsabstand (*Interquartile Range*)
oberer Whisker = $\min(\max(x), Q3 + 1.5 \cdot \text{IQR})$
unterer Whisker = $\max(\min(x), Q1 - 1.5 \cdot \text{IQR})$

Streuungsparameter

- Spannweite

$$x_{max} - x_{min}$$

- Quartilsabstand

Differenz von oberem und unterem Quartil
= Spannweite der mittleren 50% der Werte

- Mittlere absolute Abweichung

$$e = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$


- Varianz (unkorrigiert)

$$s'^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Standardabweichung (unkorrigiert)

$$s' = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Streuungsparameter: Normalverteilung




μ :	expected value,	estimated by mean value $\bar{x}$
σ^2 :	variance,	estimated by (empirical) variance s^2
σ :	standard deviation,	estimated by (empirical) standard deviation s

Die Skewness (Schiefe)

- Berechnet inwiefern die Verteilung von einer symmetrischen Verteilung Normalverteilung abweicht.
- Wird über den 3ten Moment des arithmetischen Mittels berechnet.

$$\alpha_3 = \frac{1}{n \cdot v^3} \sum_{i=1}^n (x_i - \bar{x})^3 = \frac{1}{n} \sum_{i=1}^n z_i^3$$


$$\text{where } z_i = \frac{x_i - \bar{x}}{v} \text{ and } v^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$



$\alpha_3 < 0$: right steep



$\alpha_3 = 0$: symmetric



$\alpha_3 > 0$: left steep

Die Kurtosis (Wölbung)

- Berechnet die Wölbung einer Verteilung, im Vergleich zur Normalverteilung
- Wird über den 4ten Moment des arithmetischen Mittels berechnet.

$$\alpha_4 = \frac{1}{n \cdot v^4} \sum_{i=1}^n (x_i - \bar{x})^4 = \frac{1}{n} \sum_{i=1}^n z_i^4$$

$$\text{where } z_i = \frac{x_i - \bar{x}}{v} \text{ and } v^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$



$\alpha_4 < 3$: platykurtic




$\alpha_4 = 3$: gaussian



$\alpha_4 > 3$: leptokurtic

Skala	Qualitative Merkmale		Quantitative Merkmale	
	nominal	ordinal	metrisch	
			diskret	stetig
Beispiel	Familienstand, Geschlecht, ...	Bonitätsstufen, Dienststränge, Schulnoten, ...	Einwohnerzahl, Stückzahl, Krankheitstage, ...	Zeit, Länge, Gewicht, Temperatur, Niederschlag, Blutdruck, ...
Datenerfassung	vergleichen	vergleichen	zählen	messen
Lageparameter	Modus	Median, Modus	Arithmetisches Mittel, Median	



Standardisierung der beobachteten/gemessenen Merkmale

- Z-Transformation = Standardisierung über Mittelwert und Standardabweichung
 - Alle transformierten Merkmale haben anschließend Mittelwert 0 und Standardabweichung 1.

$$\tilde{x}_i = \frac{x_i - \bar{x}}{s_x}$$


- Standardisierung über Minimal- und Maximal-Wert
 - Alle transformierten Merkmalsausprägungen liegen anschließend im Intervall [0, 1].

$$\tilde{x}_i = \frac{x_i - \min_i x_i}{\max_i x_i - \min_i x_i}$$

Standardisierung der beobachteten/gemessenen Merkmale


Boxplot nicht skaliert

```
from pydataset import data
X = data("trees") # 31 black cherry trees
X.plot.box()
```



Boxplot skaliert mittels Z-Transformation

```
X_scaled = (X - X.mean()) / X.std()
X_scaled.plot.box()
```




Visualisierung von Häufigkeitsverteilungen


Histogramm

- Gruppierung der Beobachtungswerte in Klassen (engl. *bins*)
- Darstellung der Häufigkeit je Klasse (absolut oder relativ)
- Spannweite je Klasse i.d.R. gleich


Absolute Häufigkeiten



Normierte Häufigkeiten und
Wahrscheinlichkeitsdichtefunktion (WDF, engl. *pdf*)



Original Daten



Skalierte Daten

