



Machine Learning


Lineare Regression

Bachelor Informatik/Softwaretechnik

Prof. Dr.-Ing. Max Zimmermann

Regression mit einer Variablen

Vorhersage des Immobilienpreis



Notation:


m = Anzahl der Beispiele im Trainingsdatensatz

x 's = Eingangsvariable / Merkmal

y 's = Zielvariable

Trainingsdatensatz

Größe in m ²	Preis in Tsd Euro
190	400
50	100
80	210
...	...



Wie wird h repräsentiert?

Lineare Regression mit einer Variablen
Univariate Lineare Regression

Trainingsdatensatz:


Größe in m ²	Preis in Tsd Euro
190	400
50	100
80	210
...	...

Hypothese: $h_{\theta}(x) = \theta_0 + \theta_1 x$


$\theta_{i's}$: Parameters

Wie wählen wir $\theta_{i's}$?


$$h_{\theta}(x) = \theta_0 + \theta_1 x$$




$$\begin{aligned}\theta_0 &= 1.5 \\ \theta_1 &= 0\end{aligned}$$



$$\begin{aligned}\theta_0 &= 0 \\ \theta_1 &= 0.5\end{aligned}$$



$$\begin{aligned}\theta_0 &= 1 \\ \theta_1 &= 0.5\end{aligned}$$



Idee: Wähle θ_0, θ_1 so dass $h_\theta(x)$ sehr nah an den y 's der Trainingsdaten (x,y) ist.

Hypothese:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Parameter:

$$\theta_0, \theta_1$$

Kostenfunktion:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Zielfunktion:

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

Vereinfacht

$$h_{\theta}(x) = \theta_1 x$$


$$\theta_1$$

$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\min_{\theta_1} J(\theta_1)$$


$$h_{\theta}(x)$$

(Es ist eine Funktion von x für einen festen Wert von θ_1)




$$J(\theta_1)$$

(Es ist eine Funktion über den Parameter θ_1)




$$h_{\theta}(x)$$

(Es ist eine Funktion von x für einen festen Wert von θ_1)




$$J(\theta_1)$$

(Es ist eine Funktion über den Parameter θ_1)




$$h_{\theta}(x)$$

(Es ist eine Funktion von x für einen festen Wert von θ_1)



$$J(\theta_1)$$

(Es ist eine Funktion über den Parameter θ_1)



Kostenfunktion: Partielle Ableitungen

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^i - y^i)$$

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m \theta_0 x^i + \theta_0 x^{i^2} - y^i x^i$$

Vereinfacht

$$h_{\theta}(x) = \theta_1 x$$

$$\frac{dJ(\theta_1)}{d\theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_i$$

Kostenfunktion: Partielle Ableitungen

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^i - y^i)$$

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m \theta_0 x^i + \theta_0 x^{i^2} - y^i x^i$$

Konstruktion der Kovarianz


$$s_{x,y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Der blaue Datenpunkt rechts oben in der Abb. hat einen positiven Beitrag zur Kovarianz:

$$\underbrace{(x_i - \bar{x})}_{>0} \times \underbrace{(y_i - \bar{y})}_{>0} > 0$$

- Datenpunkte in Quadrant I: positiver Beitrag zur Kovarianz
- Datenpunkte in Quadrant II: negativer Beitrag zur Kovarianz
- Datenpunkte in Quadrant III: positiver Beitrag zur Kovarianz
- Datenpunkte in Quadrant IV: negativer Beitrag zur Kovarianz

Gibt es einen positiven Zusammenhang zwischen den Datenpunkten, dann werden die meisten Datenpunkte in den Quadranten I und III liegen und viele positive Beiträge zur Kovarianz liefern. Die wenigen Datenpunkte in den Quadranten II und IV liefern zwar negative Beiträge, aber die positiven Beiträge werden überwiegen, d.h. die Kovarianz ist positiv.



Beispiel für einfache lineare Regression

i	1	2	3	4	5	Σ
x_i	2	4	3	9	7	25
y_i	4	3	6	7	8	28


$$\bar{x} = 5, \quad \bar{y} = 5,6$$

1. Varianz x $s'^2_x = 6,8$

2. Kovarianz x,y $s_{x,y} = 3,4$

3. Parameter der Regressionsgerade $\theta_1 = \frac{s_{x,y}}{s'^2_x} = 0,5$ $\theta_0 = \bar{y} - \theta_1 \bar{x} = 3,1$

4. Regressionsfunktion zur Prognose $Y = 0,5x + 3,1$



Kostenfunktion: Normalengleichung

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^i - y^i)$$

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m \theta_0 x^i + \theta_1 x^{i^2} - y^i x^i$$

- Zwei lineare Gleichungen mit zwei Unbekannten
- Gleichungssystem kann nach Methoden der linearen Algebra gelöst werden.
- Lösung ist eindeutig für unterschiedliche X-Werte

i	1	2	3	4	5	6	7	8	Σ
x_i	1	2	3	4	5	6	7	8	36
y_i	1	3	2	3	4	3	5	6	27

$$\sum_{i=1}^m x^{i^2} = 204 \quad . \quad \sum_{i=1}^m y^i x^i = 146$$

$$\theta_0 = \frac{3}{4}; \theta_1 = \frac{7}{12} \rightarrow y = \frac{3}{4} + \frac{7}{12}x$$

Korrelationskoeffizient und Bestimmtheitsmaß

Korrelationskoeffizient (nach Bravais und Pearson)

- Maß für den Grad des linearen Zusammenhangs von metrischen Merkmalen


Kovarianz

Wertebereich


$$r_{x,y} = \frac{s_{x,y}}{s'_x \cdot s'_y} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1; 1]$$

Standardabweichungen

Korrelationskoeffizient



- $r_{xy} > 0$ Die Merkmale sind positiv korreliert, die Regressionsgerade ist steigend.
- $r_{xy} = 1$ Alle Beobachtungswerte liegen exakt auf einer steigenden Geraden.
- $r_{xy} < 0$ Die Merkmale sind negativ korreliert, die Regressionsgerade ist fallend.
- $r_{xy} = -1$ Alle Beobachtungswerte liegen exakt auf einer fallenden Geraden.
- $r_{xy} = 0$ Die Merkmale sind unkorreliert, es besteht kein linearer Zusammenhang.



Korrelationskoeffizient und Bestimmtheitsmaß

Bestimmtheitsmaß (auch Determinationskoeffizient)

- Maß für erklärten Anteil der Variation einer abhängigen Variablen durch ein statistisches Modell

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\text{Variation der Residuen}}{\text{Variation von } y}$$

Bestimmtheitsmaß bei einfacher Regression

- Wie gut beschreibt die Regressionsfunktion den Zusammenhang von x und y?
- Welcher Anteil der Variation von y ist durch x erklärt?

$$R^2 = r_{x,y}^2 = \frac{s_{x,y}^2}{s_x'^2 \cdot s_y'^2}$$

Quadrat des Korrelationskoeffizienten

Beispiel für Korrelationskoeffizient und Bestimmtheitsmaß

i	1	2	3	4	5	Σ
x_i	2	4	3	9	7	25
y_i	4	3	6	7	8	28
$\hat{y}_i$	4,1	5,1	4,6	7,6	6,6	


$$\bar{x} = 5, \quad \bar{y} = 5,6$$

$$\hat{y}_i = 0,5x_i + 3,1$$

$$s'^2_x = 6,8$$

$$s'^2_y = 3,44$$

$$s_{x,y} = 3,4$$



Korrelationskoeffizient →
starke positive Korrelation!

Bestimmtheitsmaß →
~50% der Variation von y durch x erklärt

$$r = \frac{s_{x,y}}{s'_x \cdot s'_y} = \frac{3,4}{\sqrt{6,8} \cdot \sqrt{3,44}} = 0,7$$

$$R^2 = \frac{s^2_{x,y}}{s'^2_x \cdot s'^2_y} = \frac{3,4^2}{6,8 \cdot 3,44} = 0,7^2 = 0,49$$