

Größe in m ² (x)	Preis in Tsd Euro (y)
190	400
50	100
80	210
...	...

Hypothese: $h_{\theta}(x) = \theta_0 + \theta_1 x$

Größe in m ²	Anzahl Zimmer	Anzahl Stockwerke	Alter in Jahren	Preis in Tsd Euro
190	5	3	45	400
50	2	1	40	100
80	3	2	30	210
...				...

Hypothese: $h_{\theta}(x) = \theta_0 + \theta_1 x$

$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4$

z.b.: $h_{\theta}(x) = 60 + 0.1x_1 + 0.01x_2 + 4x_3 - 5x_4$

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

Wir definieren $x_0 = 1$

Kostenfunktion

Hypothese: $h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

Parameter: $\theta_0, \theta_1, \dots, \theta_n$ Kostenfunktion: $J(\theta) = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Beispiel 2 Merkmale + Zielvariable: $\sum_{i=1}^m (\theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 - y^{(i)})^2$

Partielle Ableitungen:

$$\frac{\partial J(\theta)}{\partial \theta_0} = \sum_{i=1}^m 2(\theta_0 x_0^i + \theta_1 x_1^i + \theta_2 x_2^i - y^i) x_0^i$$

$$\frac{\partial J(\theta)}{\partial \theta_1} = \sum_{i=1}^m 2(\theta_0 x_0^i + \theta_1 x_1^i + \theta_2 x_2^i - y^i) x_1^i$$

$$\frac{\partial J(\theta)}{\partial \theta_2} = \sum_{i=1}^m 2(\theta_0 x_0^i + \theta_1 x_1^i + \theta_2 x_2^i - y^i) x_2^i$$

Normalgleichungen


$$m\theta_0 + \left(\sum_{i=1}^m x_1^i\right)\theta_1 + \left(\sum_{i=1}^m x_2^i\right)\theta_2 = \left(\sum_{i=1}^m y^i\right)$$


$$\left(\sum_{i=1}^m x_1^i\right)\theta_0 + \left(\sum_{i=1}^m x_1^{i^2}\right)\theta_1 + \left(\sum_{i=1}^m x_1^i x_2^i\right)\theta_2 = \left(\sum_{i=1}^m y^i x_1^i\right)$$

$$\left(\sum_{i=1}^m x_2^i\right)\theta_0 + \left(\sum_{i=1}^m x_1^i x_2^i\right)\theta_1 + \left(\sum_{i=1}^m x_2^{i^2}\right)\theta_2 = \left(\sum_{i=1}^m y^i x_2^i\right)$$

- 3 Lineare Gleichungen für 3 Unbekannte $\theta_0, \theta_1, \theta_2$
- Kann nach Methoden der linearen Algebra gelöst werden
- Lösung ist eindeutig

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 \times \textit{stra\ss}enseite + \theta_2 \times \textit{tiefe}$$






$$\theta_0 + \theta_1 x + \theta_2 x^2$$

$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

$$\begin{aligned} h_{\theta}(x) &= \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 \\ &= \theta_0 + \theta_1(\text{größe}) + \theta_2(\text{größe})^2 + \theta_3(\text{größe})^3 \\ x_1 &= (\text{größe}) \\ x_2 &= (\text{größe})^2 \\ x_3 &= (\text{größe})^3 \end{aligned}$$



$$h_{\theta}(x) = \theta_0 + \theta_1(\text{größe}) + \theta_2(\text{größe})^2$$

$$h_{\theta}(x) = \theta_0 + \theta_1(\text{größe}) + \theta_2\sqrt{(\text{größe})}$$

Hypothese: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_n x^n$

Kostenfunktion:

$$J(\theta) = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Partielle Ableitungen auflösen für die Bestimmung des Minimums:

$$\frac{\partial J(\theta)}{\partial \theta_0} = 0, \frac{\partial J(\theta)}{\partial \theta_1} = 0, \dots, \frac{\partial J(\theta)}{\partial \theta_n} = 0$$

$$m\theta_0 + \left(\sum_{i=1}^m x^i\right)\theta_1 + \dots + \left(\sum_{i=1}^m x^{i^n}\right)\theta_n = \sum_{i=1}^m y^i$$

$$\left(\sum_{i=1}^m x^i\right)\theta_0 + \left(\sum_{i=1}^m x^{i^2}\right)\theta_1 + \dots + \left(\sum_{i=1}^m x^{i^{n+1}}\right)\theta_n = \sum_{i=1}^m y^i x^i$$

$$\vdots$$

$$\left(\sum_{i=1}^m x^{i^n}\right)\theta_0 + \left(\sum_{i=1}^m x^{i^{n+1}}\right)\theta_1 + \left(\sum_{i=1}^m x^{i^{2n}}\right)\theta_n = \sum_{i=1}^m y^i x^{i^n}$$

- $n+1$ Lineare Gleichungen für $n+1$ Unbekannte $\theta_0, \theta_1, \dots, \theta_n$
- Kann nach Methoden der linearen Algebra gelöst werden
- Lösung ist eindeutig

Gleichgewicht zwischen Verzerrung und Varianz

Mögliche Fehler bei der Modellbildung zur Klassifikation/Regression:

- **Verzerrung** Fehler ausgehend von **falschen Annahmen bei der Modellbildung (Bias)**, d.h. das Modell bildet nicht die wirkliche Beziehung zwischen Eingabe und Ausgabe ab. Ein zu einfaches Modell führt zu **Underfitting** und verzerrt die Wirklichkeit.
- **Varianz** Fehler ausgehend von **Empfindlichkeit auf kleinere Schwankungen in Trainingsdaten**. Ein Modell mit vielen Freiheitsgraden neigt zu **Overfitting**, da auch das Rauschen in den Trainingsdaten das Modell beeinflusst.
- **Nicht reduzierbare Fehler** Fehler bedingt durch **Rauschen in Trainingsdaten**. Nur zu beheben durch saubere Datenerfassung, z.B. genauere Sensoren.

Verzerrung und Varianz

Gleichgewicht zwischen Verzerrung und Varianz


Normalverteiltes Rauschen erzeugen

```
m = 100
x = np.random.rand(m) * 6 - 3 # uniform distributed random data


def f(x): return 0.5 * x**2 + x + 2;
y = f(x) + np.random.randn(m) # normal distributed random data
```

Polynomgrad 2 angenommen (weil bekannt)


```
coefs = np.polyfit(x, y, 2)
array([0.5357447, 0.95253067, 1.96805981])
```



Polynomgrad 1: Fehler aufgrund von Bias → Underfitting



Polynomgrad 18: Fehler bei Varianz in Daten → Overfitting



Regression mit mehreren unabhängigen Merkmalen

Methode der kleinsten Quadrate ist nicht auf univariate Regression beschränkt

- Einfache (= univariate) lineare Regression
- Einfache polynomiale Regression
- Multiple (= multivariate) lineare Regression
- Multiple polynomiale Regression


$$\hat{y} = \alpha_0 + \alpha_1 x$$

$$\hat{y} = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \dots + \alpha_n x^n$$

$$\hat{y}(x_1, x_2, \dots, x_m) = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_m x_m$$

$$\hat{y}(x_1, x_2) = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \alpha_3 x_1^2 + \alpha_4 x_1 x_2 + \alpha_5 x_2^2$$

Mehrere (m) unabhängige Variablen $x_a, x_b, \dots, x_m$ führen zu einem mehrdimensionalem Modell zur Prognose von y .




Multiple lineare Regression

Beispiel für Polynom 2. Grades und 2 unabhängige Variablen

$$\hat{y}(x_a, x_b) = \alpha_0 + \alpha_1 x_a + \alpha_2 x_b + \alpha_3 x_a^2 + \alpha_4 x_a x_b + \alpha_5 x_b^2$$

m Basisfunktionen aus Kombination verschiedener unabhängiger Merkmale und Polynomgrade



Multiple Polynomiale Regression

- Neue Features:

$$(x_1 + x_2 + \dots + x_m)^1 + (x_1 + x_2 + \dots + x_m)^2 + \dots + (x_1 + x_2 + \dots + x_m)^n$$

- Auflösung durch Binomialkoeffizient
- Koeffizienten nach dem Auflösen der Klammern entfallen


- Für jeden Term (Feature) wird ein θ_i geschätzt.

- Modell bleibt linear in Bezug auf $\Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_i \end{pmatrix}$,

- wobei i mit Grad des Polynoms und Anzahl der Dimensionen rasant wächst

- Bsp: 2 Dimensionen und Polynom 2 Grades

- Features: $[x_1, x_2, x_1^2, x_2^2, x_1x_2]$ 5 Koeffizienten & Achsenabschnitt müssen geschätzt werden



Regression in Scikit-learn mit dem Datensatz „Boston Housing“


“Dataset contains information collected by the US Census Service concerning housing in the area of Boston, Massachusetts.” (1978)

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	PRICE
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33	36.2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
501	0.06263	0.0	11.93	0.0	0.573	6.593	69.1	2.4786	1.0	273.0	21.0	391.99	9.67	22.4
502	0.04527	0.0	11.93	0.0	0.573	6.120	76.7	2.2875	1.0	273.0	21.0	396.90	9.08	20.6
503	0.06076	0.0	11.93	0.0	0.573	6.976	91.0	2.1675	1.0	273.0	21.0	396.90	5.64	23.9
504	0.10959	0.0	11.93	0.0	0.573	6.794	89.3	2.3889	1.0	273.0	21.0	393.45	6.48	22.0
505	0.04741	0.0	11.93	0.0	0.573	6.030	80.8	2.5050	1.0	273.0	21.0	396.90	7.88	11.9

506 rows × 14 columns

```
from sklearn.datasets import load_boston
boston = load_boston()
boston_df = pd.DataFrame(data = np.c_[boston['data'], boston['target']], columns = boston['feature_names'] + ['PRICE'])
```

<http://lib.stat.cmu.edu/datasets/boston>



Multiple lineare Regression in Scikit-learn mit dem Datensatz „Boston Housing“

Multivariates lineares Regressionsmodell anpassen

```
from sklearn.preprocessing import StandardScaler
boston_scaled = StandardScaler().fit_transform(boston['data'])

from sklearn.linear_model import LinearRegression
lm = LinearRegression().fit(boston_scaled, boston['target'])
```

Bestimmtheitsmaß des Modells bezüglich der Trainingsdaten

```
from sklearn.metrics import r2_score
r2_score(boston['target'], lm.predict(boston_scaled))
```

0.7406426641094095

Bestimmtheitsmaß zur Zielvariable und Model-Koeffizienten je Feature

```
df = pd.DataFrame({
    "feature": boston['feature_names'],
    "model coefficient": lm.coef_,
    "target R2": bostonDf.corr()[:-1].PRICE ** 2
})
df.sort_values(by=['target R2'], ascending=False)
```

feature	model coefficient	target R2
LSTAT	-3.74	0.54
RM	2.67	0.48
PTRATIO	-2.06	0.26
INDUS	0.14	0.23
TAX	-2.08	0.22
NOX	-2.06	0.18
CRIM	-0.93	0.15
RAD	2.66	0.15
AGE	0.02	0.14
ZN	1.08	0.13
B	0.85	0.11
DIS	-3.10	0.06
CHAS	0.68	0.03





Einfache polynomiale Regression in Scikit-learn mit dem Datensatz „Boston Housing“

Einfache polynomiale Regressionsmodelle
für **Polynome mit Ordnung 1 bis 4**
anpassen und visualisieren

```
f, axs = plt.subplots(ncols=4, figsize=(25, 5), sharey=True)

x = bostonDf.LSTAT
y = bostonDf.PRICE


for order in range(1, 5):
    coefs = np.polyfit(x, y, order) # fit regression coefficients
    p = np.poly1d(coefs) # polynomial function
    r2 = r2_score(y, p(x)) # calculate R squared
    seaborn.regplot(x, y, order=order, ax=axs[order-1], label="R² = {:.2f}".format(r2)) # plot
    axs[order-1].legend(markerscale=0)
```



Regression mit mehreren unabhängigen Merkmalen

Korrelation zwischen Prädiktoren


Sind die unabhängigen Merkmale in einem mehrdimensionalen Modell tatsächlich unkorreliert?



Unkorrelierte Prädiktoren

Jedes Merkmal X leistet einen unabhängigen Beitrag zur Prognose von Y.

$$R^2 = r_1^2 + r_2^2$$



Korrelierte Prädiktoren

Die Merkmale X_1 und X_2 sind korreliert und erklären Y nicht unabhängig voneinander.

$$R^2 < r_1^2 + r_2^2$$